Imię i Nazwisko: Piotr Cywoniuk	**Kierunek:** MAD	**PUNKTACJA**
Prowadzący: AK	**Numer albumu:** 338901	/ 8

Raport z Kamienia Milowego 1: Eksploracja i przygotowanie danych

1 Eksploracyjna analiza danych

Zbiór treningowy ma 6400 obserwacji i 23 cechy. Klasa 1 (default) to 21,6%, więc klasy są niezbalansowane. SEX, EDUCATION i MARRIAGE traktuję jako zmienne nominalne, a PAY_0–PAY_6 jako kody statusu spłaty, a nie zwykłe liczby. Treść projektu nie podaje znaczenia kodów PAY, więc przyjąłem interpretację: −2 brak zadłużenia, −1 terminowa spłata, 0 kredyt odnawialny ze spłatą minimum, wartości dodatnie to miesiące opóźnienia. Wartości 0, 4, 5, 6 w EDUCATION oraz 0, 3 w MARRIAGE nie są brakami, bo w pdfie są jako „inne".

Rozkłady. Kwoty PAY_AMT są mocno prawoskośne (PAY_AMT1: średnia 5916, mediana 2489). AGE mieści się w przedziale 19–73 lata, mediana to 33. Kobiety stanowią ok. 60% klientów.

Problemy w danych. Braki występują w PAY_5, BILL_AMT6 i PAY_AMT4 (po ok. 10% w każdej), a 27,23% wierszy ma co najmniej jeden brak. Usuwanie wierszy odpada, bo straciłbym ponad jedną czwartą danych, a w zbiorze testowym braki też występują. Znalazłem wartości niemożliwe: LIMIT_BAL = −157,51 i PAY_3 = −3 (po jednym wierszu). Ujemne PAY_AMT to 14–19% wartości kolumny, a ujemne BILL_AMT 13–15%. BILL_AMT6 ma podejrzane minimum −233 710.

Outliery. Według reguły 1,5 IQR to ok. 1% wartości LIMIT_BAL i 8–9,5% w pozostałych kwotach. Są to głównie naturalne długie ogony kwot. Przy wysokich wpłatach odsetek defaultów to 9,6–15,6%, a wśród pozostałych klientów 22,1–22,7%.

Relacje ze zmienną celu. Najmocniej klientów dzieli PAY_0. Odsetek defaultów dla statusu −2 to 10,9%, −1: 18,0%, 0: 12,7%, 1: 32,4%, a 2: aż 67,9%. Zależność nie jest monotoniczna, bo −1 wypada gorzej niż 0, a grupy od statusu 4 w górę są bardzo małe. Dla SEX różnica jest niewielka: mężczyźni 24,0%, kobiety 20,0%. W EDUCATION odsetek wynosi 19,7% (1), 22,7% (2), 24,5% (3) i 4,6% dla „inne" (108 osób, mała grupa). W MARRIAGE: 22,4% (1), 20,7% (2) i 32,0% dla „inne" (75 osób). Klienci z defaultem mają niższy limit (mediana ok. 90 000 wobec ok. 155 000). Zmienne BILL_AMT są silnie powiązane między miesiącami, podobnie PAY_*.

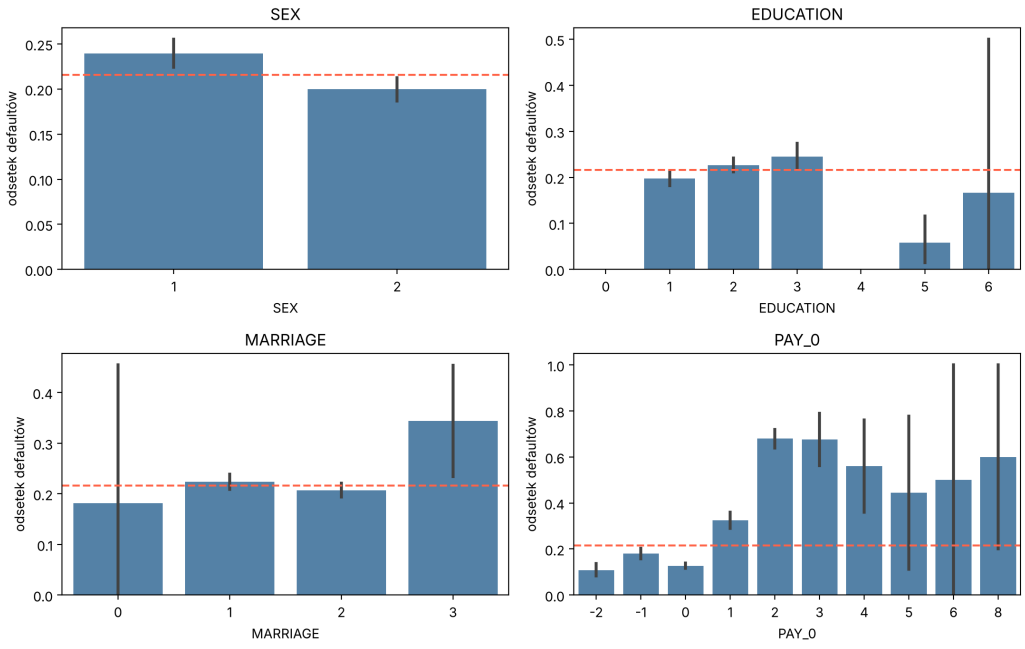


Figure 1: Odsetek defaultów w grupach SEX, EDUCATION, MARRIAGE i PAY_0. Przerywana linia to średni odsetek w całym zbiorze (21,6%).

2 Metryka ewaluacji i podział danych

Wybrałem ROC AUC. Model, który zawsze przewiduje 0, ma accuracy 78,4% i ROC AUC 0,5. ROC AUC ocenia, jak dobrze model ustawia klientów od najmniej do najbardziej ryzykownych.

2.1 Podział danych

X_test.csv nie ma y, więc dzielę dane treningowe. Zastosowałem podział 80/20 (random_state = 42): 5120 obserwacji treningowych i 1280 walidacyjnych. Hiperparametry wybieram 5-krotną walidacją krzyżową KFold na części treningowej, a zbiór walidacyjny służy tylko do końcowej oceny, żeby wynik nie był zawyżony przez przeuczenie.

3 Optymalizacja hiperparametrów drzewa decyzyjnego

Drzewo w sklearn obsługuje braki, a skala cech nie ma dla niego znaczenia. Sprawdziłem trzy hiperparametry: max_depth (2, 3, 4, 5, 6, 8, 10, 15, 25), który kontroluje złożoność drzewa; min_samples_leaf (1, 5, 10, 25, 50, 100, 200), który nie pozwala drzewu uczyć się pojedynczych klientów; oraz criterion (gini, entropy). Razem dało to 126 kombinacji.

Najlepsza okazała się kombinacja max_depth = 10, min_samples_leaf = 100, criterion = gini, z ROC AUC w CV równym 0,730. Najwięcej zmienia min_samples_leaf: przy głębokości 25 AUC rośnie z 0,591 (liść 1) do 0,728 (liść 100). Criterion prawie nic nie zmienia (0,730 wobec 0,729).

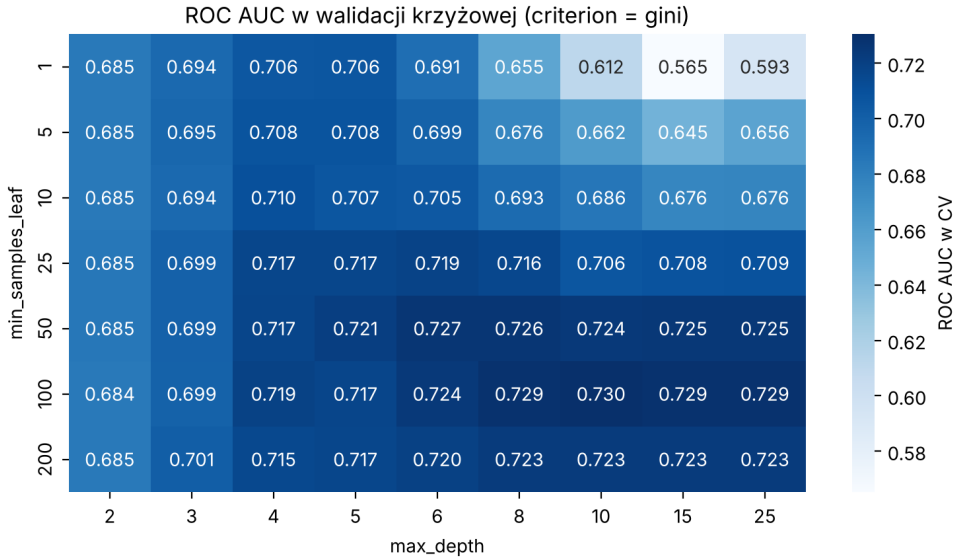


Figure 2: ROC AUC w 5-krotnej walidacji krzyżowej dla kombinacji max_depth i min_samples_leaf (criterion = gini).

Model	Głębokość	Liczba liści	AUC trening	AUC walidacja
Drzewo domyślne	31	694	0,999	0,611
Drzewo strojone	10	39	0,799	0,748

Table 1: Porównanie drzewa domyślnego i drzewa z dobranymi hiperparametrami.

Drzewo domyślne jest mocno przeuczone: prawie idealnie zapamiętuje dane treningowe, ale na walidacji wypada słabo. Drzewo strojone jest znacznie prostsze i dużo lepiej uogólnia.

4 Podsumowanie i wnioski

Najważniejsze dla przewidywania defaultu są statusy spłaty, zwłaszcza PAY_0, oraz LIMIT_BAL. Najlepsze drzewo decyzyjne osiąga ROC AUC 0,748 na zbiorze walidacyjnym.